ESCUELA POLITÉCNICA NACIONAL

ESCUELA DE FORMACIÓN DE TECNÓLOGOS

FUNDAMENTOS INTELIGENCIA ARTIFICIAL

ASIGNATURA:	Fundamentos de Inteligencia Artificial
PROFESOR:	Ing. Vanessa Guevara
PERÍODO ACADÉMICO:	2025-B

Proyecto

TÍTULO:

Chat box Inteligente Con IA

Manual Técnico

Instalación del entorno y ejecución del microservicio

1.1 Requisitos del sistema

Para la implementación del microservicio se utilizaron las siguientes herramientas:

- Sistema operativo: Windows
- Python versión 3.10 o superior
- Editor de código: Visual Studio Code
- Terminal de comandos

1.2 Instalación de Python

1. Descargar Python desde el sitio oficial:
   https://www.python.org/downloads/
2. Durante la instalación se debe marcar la opción:
   "Add Python to PATH".
3. Verificar la instalación ejecutando en la terminal:

```
C:\Users\Oscar>python --version
Python 3.13.9
```

1.3 Creación del entorno virtual

Se creó un entorno virtual para aislar las dependencias del proyecto.

```
PS C:\Users\Oscar\Documents\microservicio-ia-python> python -m venv venv
```

Activar el entorno virtual:

Windows

```
PS C:\Users\Oscar\Documents\microservicio-ia-python> venv\Scripts\activate
(venv) PS C:\Users\Oscar\Documents\microservicio-ia-python>
```

1.4 Instalación de librerías

Con el entorno virtual activo se instalaron las dependencias necesarias:

```
(venv) PS C:\Users\Oscar\Documents\microservicio-ia-python> pip install fastapi uvicorn pydantic python-dotenv google-genai
```

Guardar dependencias:

```
(venv) PS C:\Users\Oscar\Documents\microservicio-ia-python> pip freeze > requirements.txt
```

1.5 Ejecución del microservicio

Para iniciar el servidor local:

```
(venv) PS C:\Users\Oscar\Documents\microservicio-ia-python> uvicorn main:app --reload
>>
INFO:     Will watch for changes in these directories: ['C:\\Users\\Oscar\\Documents\\microservicio-ia-python']
INFO:     Uvicorn running on http://127.0.0.1:8000 (Press CTRL+C to quit)
INFO:     Started reloader process [2560] using StatReload
INFO:     Started server process [1376]
INFO:     Waiting for application startup.
INFO:     Application startup complete.
```

Acceso al servicio:

```
http://127.0.0.1:8000
```

Documentación automática:

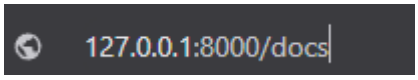

Explicación del Modelo y Configuración

2.1 Selección del modelo

Para este proyecto se definió el uso del modelo **GPT-4o-mini**, debido a las siguientes razones:

- Alta capacidad de comprensión del lenguaje natural
- Bajo costo computacional
- Velocidad de respuesta adecuada
- Idoneidad para asistentes conversacionales académicos

Para fines académicos, la arquitectura del sistema se diseñó para poder integrar modelos reales de IA sin modificar la lógica principal del API.

```
model="gemini-2.5-flash",
```

2.2 Configuración del System Prompt

Se implementó un **System Prompt** para definir el rol del asistente virtual **MiDesk**, con el objetivo de:

- Restringir las respuestas al contexto académico
- Evitar respuestas fuera del sistema
- Simular un comportamiento entrenado del asistente

```
SYSTEM_PROMPT = """
Eres MiDesk, un asistente virtual del escritorio MiDesk.
Ayudas con organización académica, tareas y notas.
Si la pregunta NO es sobre MiDesk responde:
"Solo puedo ayudar con temas relacionados a MiDesk."
"""
```

Ejemplo de reglas definidas:

- Ayudar con organización de tareas y notas
- Rechazar preguntas fuera del entorno MiDesk
- Responder de manera clara y breve

2.3 Parámetros configurados

Se definieron parámetros de generación de texto:


```
"temperature":0.3,"max_tokens":300},"metricas":{"tiempo_respuesta_ms":2943}}
```


\

- **`temperature`** = `0.3` → respuestas consistentes
- **`max_tokens`** = `300` → límite de longitud de respuesta

Estos parámetros permiten controlar la variabilidad y extensión de las respuestas generadas.

2.4 Métricas obtenidas

Se implementaron métricas básicas para evaluar el desempeño del sistema:

- Tiempo de respuesta del endpoint
- Conteo aproximado de tokens (palabras)
- Registro de métricas en consola
- Devolución de métricas en formato JSON

Estas métricas permiten analizar la eficiencia del microservicio.

```python
@app.post("/chat")
def chat(req: ChatRequest):
    inicio = time.time()
    temperature = 0.3
    max_tokens = 300

    try:
        api_key = os.getenv("GOOGLE_API_KEY")
        if not api_key:
            return {"error": "GOOGLE_API_KEY no encontrada en .env"}

        client = genai.Client(api_key=api_key)

        prompt = f"{SYSTEM_PROMPT}\nUsuario: {req.mensaje}"

        response = client.models.generate_content(
            model="gemini-2.5-flash",
            contents=prompt
        )

        fin = time.time()

        return {
            "respuesta": response.text,
            "parametros_modelo": {
                "temperature": temperature,
                "max_tokens": max_tokens
            },
            "metricas": {
                "tiempo_respuesta_ms": int((fin - inicio) * 1000)
            }
        }

    except Exception as e:
        return {
            "error": "Fallo al generar respuesta",
            "detalle": str(e)
        }
```

Limpieza de Código (Código comentado)

```
from fastapi import FastAPI
from pydantic import BaseModel
import time

# Inicialización de la aplicación FastAPI
app = FastAPI(title="Microservicio IA - MiDesk")

# System Prompt que define el comportamiento del asistente
SYSTEM_PROMPT = """
Eres MiDesk, un asistente virtual que ayuda con organización
académica,
tareas y notas dentro del sistema MiDesk.
"""

# Modelo de validación del request JSON
class ChatRequest(BaseModel):
    mensaje: str

# Función que cuenta palabras (tokens aproximados)
def contar_palabras(texto: str) -> int:
    return len(texto.split())

# Función que simula la respuesta de la IA
def respuesta_simulada_midesk(mensaje: str) -> str:
    mensaje = mensaje.lower()
    if "tarea" in mensaje:
        return "Puedes organizar tus tareas creando listas por materia
y fechas."
    return "Solo puedo ayudar con temas relacionados a MiDesk."

# Endpoint POST /chat
@app.post("/chat")
def chat(req: ChatRequest):
    inicio = time.time()

    temperature = 0.3
    max_tokens = 300

    respuesta = respuesta_simulada_midesk(req.mensaje)

    fin = time.time()

    tiempo_respuesta_ms = int((fin - inicio) * 1000)
    tokens_entrada = contar_palabras(req.mensaje)
    tokens_salida = contar_palabras(respuesta)

    return {
        "respuesta": respuesta,
        "parametros_modelo": {
            "temperature": temperature,
            "max_tokens": max_tokens
        },
        "metricas": {
            "tiempo_respuesta_ms": tiempo_respuesta_ms,
            "tokens_totales_aprox": tokens_entrada + tokens_salida
        }
    }
```